

**ANÁLISE EXPLORATÓRIA DOS RESULTADOS DE
APRENDIZADO DE REDES NEURAI**

D'ANGELO, Débora

IME USP, 19989797487, e-mail: debora.d.r.a@usp.br

MATSUMOTO, Gabriel

IME USP, 13991585585, e-mail: g.matsumoto@usp.br

NUNES, Bruna

IF USP, 19989797487, e-mail: bruna.olinunes05@usp.br

SAMPAIO, Guilherme

IME USP, 11988944493, e-mail: guilhermehsmarcelino@usp.br

RESUMO

Este artigo tem o objetivo de, utilizando análise exploratória, determinar a precisão do aprendizado de uma Rede Neural quando exposta a diferentes bases de dados e suas próprias características. especificamente no aprendizado de uma Rede Neural em como identificar algarismos escritos à mão, ensinada a partir do banco de dados EMNIST e a sua precisão quando aplicada à outro banco de dados. No final desse artigo foi possível concluir que existe uma variável ambiental quando a IA é aplicada no mundo real.

Palavras-chave: Rede Neural, Acurácia, Deep learning, Aprendizado de máquina

ABSTRACT

This paper has the main goal of utilizing a method of exploratory analysis to determine the precision of a Neural Network's learning when exposed to different databases and their own characteristics. Specifically a Neural Network's learning on how to identify handwritten numerals trained using the EMNIST database and its precision within another database. By the latest part of this paper's development, it was possible to conclude that there's an environmental variable when applying the AI in the real world.

Keywords: Neural Network, Accuracy, Deep Learning, Machine Learning

1 INTRODUÇÃO

O objetivo deste artigo é demonstrar como uma rede neural artificial, treinada em um banco de dados X, pode ter uma acurácia menor em acertar dados do banco Y por motivos diversos que serão trabalhados durante a pesquisa.

Em um momento inicial foi criada uma rede neural artificial em python, utilizando o pacote pytorch, e baseada na implementação disponível no site “medium.com”. À partir dessa rede neural fizemos vários testes com dois bancos de dados diferentes, o EMNIST, um banco de dados público, contendo aproximadamente 280000 fotos em preto e branco com resolução 28x28 pixels e o banco Sampaio-Matsumoto, criado pelo nosso grupo onde foram escritas aproximadamente 600 numerais em uma lousa do IME e tiradas fotos coloridas em resolução 320x240 pixels.

Após aplicados alguns tratamentos de imagens no banco Sampaio-Matsumoto, que serão devidamente explicados mais à frente, transformamos as fotos em preto e branco e com resolução 28x28 pixels.

Ensinamos então a Rede Neural e usamos os dois bancos para testar sua precisão, os resultados coletados foram analisados e foram encontrados alguns erros e possíveis causas para eles, que serão todos comentados melhor no restante do artigo.

2 METODOLOGIA

2.1 Criação do banco de dados

O banco de dados Sampaio-Matsumoto foi criado a partir de diversas fotos tiradas de vários algarismos escritos em uma mesma lousa do IME, para deixar a iluminação o mais consistente possível, as fotos foram tiradas coloridas, com uma resolução de 320x240 pixels, essas imagens sofreram um resize, de 320x240 para 28x28 pixels e depois foram transformadas em grayscale onde cada pixel tinha um valor de 0 a 1 para definir o quão branco possuía.

À partir dessas imagens em grayscale, definimos a taxa de iluminação como o valor no qual um algoritmo em python iria utilizar para definir se um pixel estava ativado o suficiente e então transformá-lo em branco, ou seja valor 1, ou se o pixel estivesse abaixo dessa taxa, seria então transformado em preto, ou valor 0. temos então, o banco Sampaio-Matsumoto transformado de colorido 320x240 para preto e branco 28x28.

2.2 Coleta de dados

Foi criada uma rede neural em python, com o auxílio do pacote pytorch e baseada na implementação disponível em, “medium.com”, essa Rede Neural foi treinada utilizando o banco de dados EMNIST e foram feitos testes com imagens do EMNIST e do Sampaio-Matsumoto e foram comparadas a acurácia com a qual a Rede Neural acertava qual numeral estava escrito na imagem.

Esses dados de acerto e erro para cada tentativa, serão os dados utilizados na pesquisa e analisados na hora de encontrar relações para o erro.

Durante o treinamento da rede neural foram salvos os dados de tempo e acurácia em relação ao tempo, chamados de dados de treino, serão usados para entender melhor o a velocidade de aprendizado da rede neural..

2.3 Análise dos dados

O Principal valor estatístico utilizado para entender o erro foi a chamada Precisão dado por: $PS = \frac{VP}{VP+FP}$, onde VP são os verdadeiros positivos, isto é, a quantidade de vezes que a rede neural acerta que é o algarismo, e FP são os falsos positivos, a quantidade de vezes que a rede neural erra falando que é positivo, este valor foi escolhido pelo fato de que para diversas taxas de iluminação a rede neural responde a maioria das imagens com o mesmo algarismo, causando com que a precisão seja baixa.

Também foi utilizado nos dados de treino o Erro Quadrático Médio(EQM), para decidir qual a melhor função $f(x)$ que aproxima os dados, o EQM é dado por

$\frac{1}{n} \sum_{i=1}^n (f(Tri) - Ari)$, onde n é a quantidade de valores de treino que temos, Ari é o

valor da acurácia da rede neural no ponto i , e Tri é o i -ésimo valor de tempo, o EQM foi escolhido pois é muito eficiente para dados estatísticos.

3 RESULTADO E DISCUSSÃO

A rede neural treinou com 60000 imagens, ela foi testada com 10000 imagens do banco EMNIST e 182 imagens do banco Sampaio-Matsumoto, quando testado com imagens do banco Sampaio-Matsumoto foram usados 17 taxas de iluminação diferentes, totalizando 3094 imagens diferentes de Sampaio-Matsumoto

3.1 FUNÇÃO DE APRENDIZAGEM DE UMA REDE NEURAL

Os EQM foram calculados para $n=60$, logo para cada 2000 dados era marcado o tempo e a acurácia.

Analisando a tabela 1 podemos ver que conseguimos desenvolver funções analíticas melhores que $\log x$, porém, como $\sqrt[16]{x}$ e outras são mais trabalhosas de se modelar, e $\log x$ já é boa o suficiente para mostrar que a rede neural aprende em uma velocidade logarítmica, o que é bem veloz, alcançando 99% em apenas 458.16 segundos, mostrando que o restante da análise não irá ser afetada por pouco tempo de treino.

Tabela 1 – EQM para funções analíticas

$f(x)$, Imagem $[0,1]$ restrita por constantes	EQM
$\log x$	0.0109
\sqrt{x}	0.189
$\sqrt[4]{x}$	0.069
$\sqrt[16]{x}$	0.0108

Fonte: Sampaio, G.

3.2 PRECISÃO

A Partir da tabela 2 podemos ver os melhores resultados das precisões entre as 17 taxa de iluminação para cada um dos algoritmos ao ser testada no banco MS, e comparando com a precisão de cada um dos algoritmos ao ser testada no banco EMNIST os valores são muito mais inconstantes e para 7 algoritmos é mais de 30% abaixo, considerando o desempenho total temos uma diferença de 68,6% desfavorável para o teste no Sampaio-Matsumoto.

Tabela 2 – Precisão da Rede Neural por Algoritmo em Cada Banco

Banco de Dados	0	1	2	3	4	5	6	7	8	9	Todos
EMNIST	0,994	0,999	0,994	0,994	0,996	0,993	0,993	0,986	0,991	0,986	0,993
Sampaio-Matsumoto(Máximo)	1	0,625	0,222	0,2	1	0,25	0,667	0,5	0,407	0,8	0,307

Fonte: Matsumoto, G. Sampaio, G

4 CONCLUSÃO

Como foi possível demonstrar nas tabelas de resultados, obtivemos resultados no mínimo insatisfatórios para a aplicação da rede neural no nosso banco de dados, isso se dá por conta da transformação escolhida para chegar a uma imagem 28x28 PB e a não normalização das fotos, que faz com que principalmente a iluminação varie de foto para foto, fazendo com que a imagem fique ou ativada desnecessariamente, quando utilizada uma taxa muito alta, ou a imagem fique praticamente ilegível, quando se utiliza uma taxa muito baixa, sendo que de imagem para imagem varia qual a melhor taxa de iluminação.

Essa inconsistência de iluminação não é algo para qual a nossa rede neural foi treinada, pois o EMNIST não possui esse tipo de inconsistência, por isso ao testar com os dados normalizados do EMNIST a rede neural teve um desempenho melhor.

Concluimos então que treinar a rede neural em um banco de dados que não englobe todos as possíveis características que a rede neural irá ver durante os testes irá causar diversos erros e diminuir a precisão da rede neural, e que a escolha do banco de dados a ser usado para treino é um ponto extremamente importante quando se está criando a rede neural.

REFERÊNCIAS

COHEN, G., AFSHAR, S., TAPSON, J., & VAN SCHAIK, A. (2017). **EMNIST: an extension of MNIST to handwritten letters**. Retirado de: <http://arxiv.org/abs/1702.05373>

HELEODORO, T. SILVA, I. DANTE, R. GERHARDT, I. YASSITEPE, J. BARIANI, J. DE-LUCCA, P. ARRUDA, P. CANÇADO, G. **Transformação genética de cana-de-açúcar por *Agrobacterium tumefaciens***. In: Congresso Interinstitucional De Iniciação Científica, Campinas Anais, p. 1-8., 2018

NEO, B. **Building an Image Classification Model From Scratch Using PyTorch**. Disponível em: <https://medium.com/bitgrit-data-science-publication/building-an-image-classification-model-with-pytorch-from-scratch-f10452073212>

MOCELLIN, M. **Avaliação do uso de métodos univariados baseados na suavização exponencial na previsão de curto prazo de produtos com diferentes padrões de demanda**. disponível em: <https://repositorio.ufsc.br/handle/123456789/224544>

banco de dados e algoritmo utilizados nesse artigo e criados pelo grupo: <https://github.com/GuiHSM/AnaliseRedeNeuralAlgarismo>